

Dijital Oyun Kullanımı ve Psikolojik Faktörlerin Oyun Bağımlılığı Riski Üzerindeki Etkisinin Veri Analizi ve Makine Öğrenmesi Yöntemleri ile İncelenmesi

Emre AYVAZ¹

¹ Necmettin Erbakan Üniversitesi, Mühendislik Fakültesi, Bilgisayar Mühendisliği Bölümü, Konya, Türkiye

Makale Bilgisi

ÖZET

Geliş Tarihi: -
Kabul Tarihi: -
Yayın Tarihi: -

Anahtar Kelimeler:

Dijital Oyunlar,
Oyun Bağımlılığı,
Veri Analizi,
Makine Öğrenmesi,
Sınıflandırma

Bu çalışmada, Kaggle platformundan elde edilen 1000 katılımcıdan oluşan “Gaming and Mental Health” veri seti kullanılarak dijital oyun kullanım alışkanlıklarının psikolojik etkileri incelenmiş ve oyun bağımlılığı risk seviyesinin veri analizi ve makine öğrenmesi yöntemleriyle sınıflandırılması amaçlanmıştır. Veri ön işleme sürecinde eksik veriler ortalama ile doldurulmuş, aykırı değerler IQR yöntemi ile düzeltilmiş ve kategorik değişkenler sayısal hale getirilmiştir. Sınıf dengesizliği SMOTE yöntemi ile giderilmiştir. KNN, Random Forest ve Lojistik Regresyon algoritmaları karşılaştırılmıştır. 30 farklı tekrar sonucunda Random Forest (%80.97) ve Lojistik Regresyon (%80.50) yüksek doğruluk elde ederken KNN (%73.38) daha düşük performans göstermiştir. Wilcoxon testi, RF ve LR arasında anlamlı fark olmadığını, ancak her ikisinin de KNN’den daha başarılı olduğunu göstermektedir. Elde edilen bulgular, oyun bağımlılığı riskinin psikolojik faktörlerle ilişkili olduğunu ve makine öğrenmesi yöntemlerinin bu riskin tahmininde etkili olduğunu göstermektedir.

Gaming Addiction Risk Analysis Using Data Analysis and Machine Learning Methods

Article Info

ABSTRACT

Received: -
Accepted: -
Published: -

Keywords:

Digital Games,
Gaming Addiction,
Data Analysis,
Machine Learning,
Classification

This study aims to analyze gaming addiction risk using data analysis and machine learning methods based on the “Gaming and Mental Health” dataset obtained from Kaggle, consisting of 1000 participants.

During preprocessing, missing values were handled using mean imputation, outliers were treated using the IQR method, and categorical variables were transformed into numerical form. Class imbalance was addressed using SMOTE.

KNN, Random Forest, and Logistic Regression models were compared. Based on repeated evaluations with 30 different random seeds, Random Forest (80.97%) and Logistic Regression (80.50%) achieved higher accuracy, while KNN (73.38%) showed lower performance. The Wilcoxon test indicated no significant difference between Random Forest and Logistic Regression, but both outperformed KNN.

The results show that gaming addiction risk is related to psychological factors and that machine learning methods provide an effective approach for prediction.

Sorumlu Yazar: Emre Ayvaz, emreayvaz.dev@gmail.com



This article is licensed under a Creative Commons Attribution-NonCommercial 4.0 International License (CC BY-NC 4.0)

1. GİRİŞ

Dijital oyunlar günümüzde farklı yaş gruplarından bireyler tarafından yaygın biçimde kullanılan ve giderek bireylerin psikolojik deneyimlerini doğrudan etkileyen platformlar hâline gelmektedir. Teknolojik gelişmeler ve internet erişiminin artmasıyla birlikte oyun oynama süreleri önemli ölçüde artmış; bu durum oyunların bireylerin ruh hâli, uyku kalitesi ve sosyal yaşamları üzerindeki etkilerinin araştırılmasını zorunlu kılmıştır.

Dünya Sağlık Örgütü (WHO) 2018 yılında oyun bozukluğunu (gaming disorder) ICD-11 kapsamına alarak konuyu küresel bir halk sağlığı sorunu olarak tanımlamıştır. Oyun bağımlılığı riskinin erken tespiti; bireylere zamanında müdahale edilmesine, klinik değerlendirmelere destek sağlanmasına ve toplumsal farkındalığın artırılmasına katkı sağlayabilmektedir. Bu bağlamda dijital oyun kullanımının bireyler üzerindeki etkilerinin veri odaklı yöntemlerle incelenmesi büyük önem taşımaktadır.

Bu çalışmada, dijital oyun alışkanlıklarının bireylerin psikolojik ve sosyolojik durumları üzerindeki etkileri çok değişkenli bir veri seti kullanılarak analiz edilmekte ve oyun bağımlılığı risk seviyesi (Low / Moderate / High / Severe) üç farklı makine öğrenmesi algoritması ile sınıflandırılmaktadır. Çalışmanın temel amacı, bireylerin oyun oynama alışkanlıkları ile bağımlılık riski arasındaki ilişkiyi ortaya koymak ve bu riski tahmin edebilen bir model geliştirmektir.

Araştırma Soruları

Bu çalışma kapsamında aşağıdaki dört araştırma sorusuna yanıt aranmıştır:

S1: Günlük oyun oynama süresi ile bireylerin uyku kalitesi arasında anlamlı bir ilişki var mıdır?

S2: Oynanan oyun türü bireylerin sosyal izolasyon düzeyini etkiler mi?

S3: Ruh hâli ve yoksunluk belirtileri gibi psikolojik göstergeler, oyun bağımlılığı riski ile ilişki içinde midir?

S4: Makine öğrenmesi algoritmaları kullanılarak bireylerin oyun bağımlılığı riski başarılı biçimde tahmin edilebilir mi?

Motivasyon ve Arka Plan

Dijital oyun bağımlılığı günümüzde özellikle genç bireyler arasında hızla artan bir problem olarak karşımıza çıkmaktadır. Oyunların kontrolsüz kullanımı; uyku bozuklukları, akademik performans düşüşü, sosyal izolasyon ve psikolojik rahatsızlıklar gibi birçok olumsuz sonuca yol açabilmektedir.

Bu nedenle bağımlılık riskinin erken aşamada belirlenmesi büyük önem taşımaktadır. Veri analizi ve makine öğrenmesi yöntemleri, bu tür karmaşık ilişkilerin ortaya çıkarılmasında güçlü araçlar sunmaktadır. Bu çalışma, bu yöntemleri kullanarak gerçek dünya problemlerine veri temelli çözümler sunmayı amaçlamaktadır.

Literatür Araştırması

Koral ve Alptekin [1], dijital oyun bağımlılığını literatür temelinde incelemiş; aşırı kullanımın bireylerin psikolojik ve sosyal yaşamı üzerinde olumsuz etkiler oluşturduğunu ortaya koymuştur. Çakır [2], lise öğrencileri üzerinde gerçekleştirdiği çalışmada oyun bağımlılığı ile yalnızlık arasında anlamlı bir ilişki bulunduğunu belirlemiştir. Bozkurt [3] ise üniversite öğrencileri üzerinde yaptığı çalışmada dijital oyun bağımlılığının çeşitli psikolojik özellikler ile ilişkili olduğunu göstermiştir.

Uluslararası literatürde Kuss ve Griffiths [4], internet oyun bağımlılığını sistematik bir derleme

ile incelemiş ve bu durumun klinik bir bozukluk olarak değerlendirilmesi gerektiğini vurgulamıştır. Lemmens, Valkenburg ve Peter [5], oyun bağımlılığı ile sosyal izolasyon ve depresyon arasında güçlü bir ilişki olduğunu ortaya koymuştur. Granic, Lobel ve Engels [6] ise dijital oyunların bilişsel gelişime katkı sağlayabileceğini, ancak kontrolsüz kullanımın kaygı ve depresyon gibi olumsuz sonuçlara yol açabileceğini belirtmiştir.

Bununla birlikte, son yıllarda yapılan çalışmalar dijital oyun bağımlılığının yalnızca bireysel psikolojik faktörlerle değil, aynı zamanda sosyal çevre, yaşam tarzı ve davranışsal alışkanlıklarla da yakından ilişkili olduğunu göstermektedir. Özellikle oyun süresi, uyku düzeni ve sosyal etkileşim düzeyi gibi değişkenlerin bağımlılık riskini etkileyen önemli faktörler olduğu vurgulanmaktadır.

Literatürde yer alan birçok çalışma, sınırlı sayıda değişken kullanılması veya küçük örneklem büyüklükleri ile gerçekleştirilmesi nedeniyle genellenebilirlik açısından bazı kısıtlar içermektedir. Ayrıca bu çalışmaların büyük bir kısmı yalnızca istatistiksel analizlere dayanmakta olup, makine öğrenmesi yöntemleri ile kapsamlı model karşılaştırmalarına yeterince yer verilmemektedir.

Bu çalışma, 1000 katılımcıdan oluşan çok değişkenli bir veri seti üzerinde birden fazla makine öğrenmesi algoritmasını karşılaştırmalı olarak uygulaması, sınıf dengesizliği problemini SMOTE yöntemi ile ele alması ve model performanslarını istatistiksel testler ile değerlendirmesi bakımından literatüre özgün bir katkı sunmaktadır.

2. MATERYAL VE METOT

2.1. Materyal

Bu çalışmada, dijital oyun alışkanlıklarının bireylerin psikolojik ve sosyolojik durumları üzerindeki etkilerini analiz etmek amacıyla Kaggle platformu üzerinden erişime açılan “Gaming and Mental Health” veri seti kullanılmıştır. Veri seti, dünya genelindeki katılımcılardan anonim bir çevrimiçi anket yöntemiyle toplanmış olup akademik araştırmalarda kullanılmak üzere hazırlanmıştır.

Veri seti toplamda **1000 katılımcıya ait gözlemden** oluşmakta olup her bir gözlem için **27 farklı değişken** tanımlanmıştır. Veri setinde yer alan değişkenler; demografik özellikler, oyun davranışları, sağlık ve fiziksel etkiler ile psikolojik ve sosyal göstergeler olmak üzere dört ana başlık altında değerlendirilmektedir. Bu kapsamda veri seti; yaş ve cinsiyet bilgileri, günlük oyun oynama süresi, tercih edilen oyun türleri ve kullanılan platformların yanı sıra uyku düzeni, fiziksel şikayetler, sosyal izolasyon düzeyi ve bireylerin psikolojik durumlarını yansıtan göstergeleri içermektedir.

Veri setinin yapısal özelliklerini incelemek amacıyla yapılan analizlerde, değişkenlerin veri tipleri ve eksik veri durumları değerlendirilmiştir. Elde edilen bulgular, bazı değişkenlerde eksik veri bulunduğunu ve veri setinin hem sayısal hem de kategorik değişkenler içerdiğini göstermektedir.

Sayısal değişkenlerin genel dağılımını, merkezsel eğilimlerini ve değişkenliklerini belirlemek amacıyla istatistiki tanımlayıcı analizler gerçekleştirilmiş ve elde edilen sonuçlar **Tablo 1**'de sunulmuştur.

Tablo 1

Veri Setindeki Temel Sayısal Değişkenlerin İstatistiksel Özeti

Variable	Count	Mean	Std	Min	50% (Median)	Max
Age	1000	20.47	4.11	13.00	20.00	35.00
Daily Gaming Hours	1000	6.15	2.86	0.50	6.00	15.10
Sleep Hours	1000	5.73	1.44	3.00	5.70	9.00
GPA*	754	2.51	0.87	1.01	2.53	4.00
Work Productivity Score*	674	5.39	2.89	1.00	5.00	10.00
Weight Change (kg)	1000	1.51	1.43	0.00	1.10	8.90
Weekly Exercise Hours	1000	6.94	1.80	0.70	7.00	11.50
Social Isolation Score	1000	3.87	2.09	1.00	4.00	10.00
Face-to-Face Social Hours	1000	7.65	3.75	0.00	8.00	16.70
Monthly Game Spending (USD)	1000	105.22	113.89	0.10	66.41	499.27
Years of Gaming	1000	5.80	3.78	1.00	5.00	20.00


Tablo 1’de veri setindeki temel sayısal değişkenlere ait istatistiki özet değerler sunulmaktadır. Elde edilen sonuçlara göre katılımcıların yaş ortalaması **20,47** olup günlük ortalama oyun süresi **6,15 saat**, uyku süresi ortalaması ise **5,73 saat** olarak belirlenmiştir. Bu bulgular, bireyler arasında oyun alışkanlıkları ve yaşam düzeni açısından belirgin farklılıklar bulunduğunu göstermektedir.

Ayrıca bazı değişkenlerde eksik verilerin bulunduğu, tablo içerisinde yer alan “kayıt sayısı” değerlerindeki farklılıklardan anlaşılmaktadır. Genel olarak değerlendirildiğinde, veri setinin geniş bir dağılıma sahip olduğu ve bireyler arasında davranışsal çeşitliliğin yüksek olduğu görülmektedir.

Not: Okunabilirliği artırmak amacıyla tabloda yalnızca temel sayısal değişkenlere yer verilmiştir.

Veri setinde bulunan diğer değişkenler bu tabloda gösterilmemiştir.

Çalışmanın sınıflandırma hedefi olan *gaming_addiction_risk_level* (oyun bağımlılığı risk seviyesi), “Low”, “Moderate”, “High” ve “Severe” olmak üzere dört farklı sınıftan oluşmaktadır. Katılımcıların bu risk gruplarına göre dağılımı **Şekil 1**’de sunulmuştur.



Şekil 1

Oyun Bağımlılığı Risk Seviyelerine Göre Sınıf Dağılımı

Şekil 1 incelendiğinde, katılımcıların %51,4’ünün düşük risk grubunda yer aldığı, en az temsil edilen sınıfın ise %14,2 ile yüksek risk (“Severe”) grubu olduğu görülmektedir. Orta ve yüksek risk gruplarının toplam dağılımı, düşük risk grubuna kıyasla daha sınırlı kalmaktadır. Bu durum veri setinde belirgin bir sınıf dengesizliği bulunduğunu açıkça göstermektedir.

2.2. Metot

2.2.1. Eksik Veri Analizi ve Önlemler

Veri setinde yapılan inceleme sonucunda iki değişkende eksik veri bulunduğu tespit edilmiştir. *grades_gpa* değişkeninde 246 (%24,6) ve *work_productivity_score* değişkeninde 326 (%32,6) eksik gözlem yer almaktadır.

Eksik değerler, veri kaybını önlemek amacıyla ilgili sütunların aritmetik ortalaması ile tamamlanmıştır (mean imputation). Bu yöntem, veri dağılımını büyük ölçüde koruması nedeniyle tercih edilmiştir.


Ayrıca analiz açısından anlamlı katkı sağlamayan *record_id* ve *Timestamp* değişkenleri veri setinden çıkarılmıştır. Bu işlemler sonucunda veri seti modelleme süreci için uygun hale getirilmiştir..

2.2.2. Aykırı Değer Analizi ve Önilem

Seçili sayısal değişkenlerdeki aykırı değerler IQR yöntemi kullanılarak belirlenmiştir. Bu kapsamda alt sınır $Q1 - 1.5 \times IQR$ ve üst sınır $Q3 + 1.5 \times IQR$ olarak hesaplanmıştır.

Belirlenen sınırların dışında kalan değerler veri setinden çıkarılmak yerine clipping yöntemi ile sınır değerlere çekilmiştir. Bu yaklaşım, veri kaybını önleyerek model performansının daha kararlı olmasına katkı sağlamaktadır.

Uygulanan işlem sonrasında aykırı değerlerin etkisi azaltılmış ve veri dağılımı daha dengeli hale getirilmiştir. Seçili sayısal değişkenlere ait son durum Şekil 2’de sunulmuştur.



Şekil 2

Seçili Sayısal Değişkenlere Ait Aykırı Değer Analizi Boxplot Grafiği

Şekil 2 incelendiğinde, aykırı değerlerin büyük ölçüde giderildiği ve değişkenlerin daha dengeli bir dağılım sergilediği görülmektedir.

2.2.2. Özellik Seçimi ve Mühendisliği


Veri setindeki değişkenlerin model performansına katkısını artırmak ve gereksiz karmaşıklık azaltmak amacıyla özellik seçimi ve mühendisliği süreçleri uygulanmıştır. Bu kapsamda analiz açısından istatistiksel anlam taşımayan ve modele katkı sağlamayan *record_id* ve *Timestamp* gibi kimlik ve zaman bilgisi içeren değişkenler veri setinden çıkarılmıştır.

Yapılan analizler sonucunda, hedef değişken ile doğrudan kavramsal örtüşme veya yüksek korelasyon içeren bazı değişkenlerin veri sızıntısı (data leakage) riski oluşturduğu belirlenmiştir. Bu nedenle *daily_gaming_hours*, *sleep_disruption_frequency*, *mood_state* ve *withdrawal_symptoms* değişkenleri modelleme sürecine dahil edilmemiştir. Bu yaklaşım, modelin gerçek dünya verilerine daha iyi genellenebilir sonuçlar üretmesini sağlamak açısından önem taşımaktadır.

Ayrıca mevcut değişkenlerden yararlanılarak yeni bir özellik türetilmiştir. Bu kapsamda oluşturulan *gaming_intensity* değişkeni, bireylerin günlük oyun süresinin yaşa göre normalize edilmesiyle elde edilmiştir ($gaming_intensity = daily_gaming_hours / (age + 1)$). Bu özellik, farklı yaş gruplarındaki bireylerin oyun yoğunluğunu karşılaştırılabilir hale getirerek modele ek açıklayıcı bilgi sağlamaktadır.

Değişkenler arasındaki doğrusal ilişkileri incelemek amacıyla Pearson korelasyon analizi gerçekleştirilmiş ve elde edilen sonuçlar Şekil 3'te sunulmuştur.

Son olarak, makine öğrenmesi algoritmalarının kullanılabilmesi amacıyla kategorik değişkenler uygun kodlama yöntemleri ile sayısal formata dönüştürülmüştür.



Şekil 3


Pearson Korelasyon Matrisi Isı Haritası

Şekil 3 incelendiğinde, değişkenler arasında pozitif ve negatif yönlü korelasyonların bulunduğu görülmektedir. Bazı değişken çiftleri arasında daha belirgin ilişkilerin olduğu dikkat çekmektedir.

2.2.3. Görselleştirme (EDA)

Veri setinin genel yapısını anlamak ve araştırma sorularına görsel yanıtlar üretmek amacıyla çeşitli grafikler hazırlanmıştır.


Şekil 4'te günlük oyun süresi dağılımı histogram ile gösterilmektedir. Dağılımın hafif sağa çarpık bir yapı sergilediği görülmektedir.



Şekil 4
Günlük Oyun Süresi Dağılımı Histogram Grafiği

Katılımcıların büyük çoğunluğunun günde 4–8 saat arasında oyun oynadığı görülmektedir. 10 saatin üzerindeki değerler olası bağımlılık riskini yansıtabilecek bireyler olarak değerlendirilebilir.


Araştırma sorusu S1 kapsamında risk seviyesine göre uyku süresi dağılımı incelenmiştir. Şekil 5'teki boxplot, risk seviyesi arttıkça uyku süresi medyan değerinin azaldığını göstermektedir.



Şekil 5
Risk seviyesine göre uyku süresi dağılımı boxplot (Araştırma Sorusu S1)

Low grubunda uyku süresi medyanı yaklaşık 6,5 saat iken Severe grubunda bu değer 4,5 saatin altına inmektedir. Bu bulgu, oyun bağımlılığı riski ile uyku kalitesi arasında olumsuz bir ilişki bulunduğunu desteklemektedir.

Araştırma sorusu S2 kapsamında oyun türüne göre sosyal izolasyon skoru incelenmiştir. Şekil 6'da oyun türleri arasında sosyal izolasyon medyan değerlerinin farklılaştığı görülmektedir.




Şekil 6

Oyun türüne göre sosyal izolasyon skoru dağılımı (Araştırma Sorusu S2)

Bu durum, oynanan oyun türünün bireylerin sosyal yaşamı üzerinde farklı etkiler oluşturabileceğine işaret etmektedir.

Araştırma sorusu S3 kapsamında ruh hâli (*mood_state*) ve yoksunluk belirtileri (*withdrawal_symptoms*) değişkenlerinin bağımlılık riski ile ilişkisi görselleştirilmiştir. Bu değişkenler veri sızıntısı riski nedeniyle modele dahil edilmemiş; ancak görsel analiz önemli bulgular ortaya koymuştur.




Şekil 7

Ruh hâline göre bağımlılık risk seviyesi dağılımı (Araştırma Sorusu S3)

Şekil 7 incelendiğinde, olumsuz ruh hâli (Anxious, Depressed, Irritable) bildiren bireylerde yüksek ve ciddi risk kategorilerinin diğer gruplara kıyasla belirgin biçimde daha yoğun olduğu görülmektedir.

Şekil 8’de yoksunluk belirtisi yaşayan bireylerde yüksek ve ciddi risk kategorilerinin oranının belirgin şekilde daha fazla olduğu görülmektedir.



Şekil 8

Yoksunluk belirtilerine göre bağımlılık risk seviyesi dağılımı (Araştırma Sorusu S3)

Şekil 7 ve Şekil 8 birlikte değerlendirildiğinde, psikolojik göstergelerin bağımlılık riski ile güçlü bir ilişki içinde olduğu anlaşılmaktadır.

2.2.4. Veri Dönüştürme ve Bölme

Makine öğrenmesi algoritmalarının uygulanabilmesi amacıyla veri setindeki kategorik değişkenler uygun kodlama yöntemleri ile sayısal formata dönüştürülmüştür. Bu kapsamda her bir kategorik değişken için ayrı kodlama işlemi gerçekleştirilmiş ve veri seti algoritmalar için uygun hale getirilmiştir.

Modelin eğitim ve test süreçlerinin sağlıklı bir şekilde yürütülebilmesi amacıyla veri seti eğitim ve test kümelerine ayrılmıştır. Bu işlemde sınıf dağılımının korunması için stratified sampling yöntemi kullanılmış ve veri seti %70 eğitim ve %30 test olacak şekilde bölünmüştür.

Eğitim verisi üzerinde sınıf dengesizliğini gidermek amacıyla SMOTE (Synthetic Minority Over-sampling Technique) yöntemi uygulanmıştır. Test verisi ise modelin gerçek performansını değerlendirebilmek amacıyla olduğu gibi bırakılmıştır. Bu yaklaşım, veri sızıntısının önlenmesine katkı sağlamaktadır.

3. BULGULAR VE TARTIŞMA

3.1. Modelleme Yaklaşımı ve Algoritmaların Uygulanması

Bu çalışmada, oyun bağımlılığı risk seviyesinin sınıflandırılması amacıyla üç farklı makine öğrenmesi algoritması kullanılmıştır: K-En Yakın Komşu (KNN), Rastgele Orman (Random Forest) ve Lojistik Regresyon. Bu algoritmalar, önileme adımları tamamlanmış veri seti üzerinde ayrı ayrı eğitilmiş ve test edilmiştir.

Model performanslarının güvenilir bir şekilde değerlendirilmesi amacıyla farklı rastgele başlangıç değerleri (random seed) kullanılarak tekrarlı eğitimler gerçekleştirilmiştir. Bu yaklaşım, model sonuçlarının tek bir veri bölünmesine bağlı kalmasını önleyerek daha genellenebilir sonuçlar elde edilmesini sağlamaktadır.

Her bir algoritma için hiperparametre optimizasyonu GridSearchCV yöntemi kullanılarak gerçekleştirilmiştir. Bu kapsamda, farklı parametre kombinasyonları denenmiş ve en iyi performansı sağlayan parametreler belirlenmiştir.


Modellerin performanslarını değerlendirmek amacıyla accuracy, precision, recall ve F1-score metriklerinden yararlanılmıştır. Ayrıca sınıflandırma sonuçları karışıklık matrisi ile analiz edilmiştir. Bununla birlikte, modellerin performansları istatistiksel testler ile karşılaştırılarak elde edilen farkların anlamlılığı incelenmiştir..

3.2. K-En Yakın Komşu (KNN) Modeli

K-En Yakın Komşu (KNN) algoritması, örnekler arasındaki mesafeyi temel alarak sınıflandırma yapan parametrik olmayan bir yöntemdir. Veri noktaları arasındaki benzerlik ilişkilerine göre karar veren bu algoritma, mesafe temelli çalıştığından veri setine StandardScaler yöntemiyle ölçeklendirme uygulanmıştır.

3.2.1. Başlangıç (Baseline) Model Sonuçları

Varsayılan hiperparametreler ($k=5$) kullanılarak oluşturulan başlangıç modeli test veri seti üzerinde %70.7 doğruluk elde etmiştir. Modelin genel performansı incelendiğinde macro F1-score değeri 0.60 olarak hesaplanmıştır.



Şekil 9

KNN Başlangıç Modeli ($K=5$) Karışıklık Matrisi

Tablo 5*KNN Başlangıç Modeli Performans Sonuçları*

Sınıf	Precision	Recall	F1-Score	Support
High	0.46	0.56	0.50	57
Low	0.33	0.37	0.35	46
Moderate	0.97	0.90	0.93	154
Severe	0.71	0.56	0.62	43
Accuracy			%70.7	300
Ortalama	0.61	0.60	0.60	300

Tablo 5 incelendiğinde modelin özellikle Moderate sınıfında yüksek performans gösterdiği (F1=0.93), ancak Low sınıfında düşük başarı elde ettiği (F1=0.35) görülmektedir. Bu durum sınıf dengesizliğinin KNN performansını olumsuz etkilediğini ortaya koymaktadır.

3.2.2. Hiperparametre Optimizasyonu

KNN modelinin performansını artırmak amacıyla GridSearchCV yöntemi kullanılarak k=3 ile k=49 aralığında farklı komşu sayısı değerleri denenmiştir. Yapılan optimizasyon sonucunda en iyi parametre değeri k=3 olarak belirlenmiştir.

Tablo 6*Gridsearchcv Sonrası Optimize KNN Modeli (K=3) Performans Sonuçları.*

Sınıf	Precision	Recall	F1-Score	Support
High	0.48	0.56	0.52	57
Low	0.36	0.39	0.38	46
Moderate	0.95	0.92	0.93	154
Severe	0.68	0.53	0.60	43
Accuracy			%71.7	300
Ortalama	0.62	0.60	0.61	300

Optimizasyon sonrası model performansı incelendiğinde doğruluk değerinde belirgin bir iyileşme gözlemlenmemiştir (%70.7'den %71.7'ye). Bu durum KNN algoritmasının bu veri seti yapısında k parametresine duyarlı olduğunu göstermektedir.

3.2.3. Genel Değerlendirme


Başlangıç ve optimize model sonuçları birlikte değerlendirildiğinde KNN algoritmasının veri seti yapısına bağlı olarak sınırlı performans sergilediği görülmektedir. Özellikle sınıf dengesizliği nedeniyle modelin Low ve High sınıflarını ayırt etmekte zorlandığı anlaşılmaktadır.

3.3. Rastgele Orman (Random Forest) Modeli

Rastgele Orman, çok sayıda karar ağacının bir araya gelmesiyle oluşturulan bir topluluk öğrenme algoritmasıdır. Her ağaç rastgele seçilen özellik alt kümeleri üzerinde eğitilir; tahminler oy çokluğuyla belirlenir. Mesafe hesabına dayanmadığından ölçeklendirme gerekmez.

3.3.1. Başlangıç (Baseline) Model Sonuçları

Varsayılan parametrelerle kurulan başlangıç modeli test veri seti üzerinde %80.3 doğruluk elde etmiştir. KNN'e kıyasla tüm sınıflarda belirgin iyileşme gözlemlenmiş; macro F1-score değeri 0.73 olarak hesaplanmıştır.



Şekil 10

Random Forest Başlangıç Modeli Karışıklık Matrisi

Tablo 7

Random Forest Başlangıç Modeli Performans Sonuçları

Sınıf	Precision	Recall	F1-Score	Support
High	0.59	0.65	0.62	57
Low	0.49	0.52	0.51	46
Moderate	0.97	0.95	0.96	154
Severe	0.89	0.79	0.84	43
Accuracy			%80.3	300
Ortalama	0.74	0.73	0.73	300

Tablo 7 incelendiğinde modelin özellikle Moderate (F1=0.96) ve Severe (F1=0.84) sınıflarında güçlü sonuçlar elde ettiği görülmektedir. KNN'e kıyasla tüm sınıflarda belirgin performans artışı gerçekleşmiştir.

3.3.2. Hiperparametre Optimizasyonu

GridSearchCV yöntemi ile max_depth=[5, 10, None] ve n_estimators=[100, 200] parametre kombinasyonları denenmiştir. Optimizasyon sonucunda en iyi parametreler max_depth=None ve n_estimators=100 olarak belirlenmiştir.

Tablo 8

Gridsearchcv Sonrası Optimize Random Forest Modeli (Max_Depth=None, N=100) Performans Sonuçları

Sınıf	Precision	Recall	F1-Score	Support
High	0.59	0.68	0.63	57
Low	0.43	0.43	0.43	46
Moderate	0.97	0.95	0.96	154
Severe	0.86	0.74	0.80	43
Accuracy			%79.3	300
Ortalama	0.72	0.70	0.71	300

Optimize model %79.3 doğruluk elde etmiştir. 30 tekrarlı değerlendirmede ise Random Forest ortalama %81.4 doğrulukla tüm modeller arasında birinci sıraya yerleşmiş ve 30 denemeden 20'sinde en yüksek doğruluğa ulaşmıştır.

3.3.3. Genel Değerlendirme


Random Forest, KNN'in önemli ölçüde üzerinde performans sergilemiş ve tekrarlı öğrenme değerlendirmesinde en yüksek ortalama doğruluğa ulaşmıştır. Topluluk öğrenme yapısı sayesinde sınıf dengesizliğine karşı daha dayanıklı bir model elde edilmiştir.

3.4. Lojistik Regresyon Modeli

Lojistik Regresyon, doğrusal karar sınırları oluşturan ve katsayı yorumlanabilirliğiyle öne çıkan bir sınıflandırma algoritmasıdır. Hangi değişkenin bağımlılık riskini hangi yönde etkilediğini katsayılar aracılığıyla doğrudan göstermesi klinik yorumlama açısından önemli bir avantaj sunmaktadır. Tahmin kararlılığını artırmak amacıyla StandardScaler uygulanmıştır.

3.4.1. Başlangıç (Baseline) Model Sonuçları

Varsayılan $C=1.0$ parametresiyle kurulan başlangıç modeli test veri seti üzerinde %80.7 doğruluk elde etmiştir. Tüm başlangıç modelleri arasında en yüksek doğruluğa ulaşılmış; macro F1-score değeri 0.73 olarak hesaplanmıştır.



Şekil 11

Lojistik Regresyon Başlangıç Modeli Karışıklık Matrisi

Tablo 9

Lojistik Regresyon Başlangıç Modeli Performans Sonuçları

Sınıf	Precision	Recall	F1-Score	Support
High	0.61	0.68	0.64	57
Low	0.48	0.52	0.50	46
Moderate	0.99	0.95	0.97	154
Severe	0.86	0.74	0.80	43
Accuracy			%80.7	300
Ortalama	0.74	0.73	0.73	300

Tablo 9 değerlendirildiğinde Lojistik Regresyon'un tüm başlangıç modelleri arasında en dengeli sonuçları verdiği görülmektedir. Moderate ($F1=0.97$) ve Severe ($F1=0.80$) sınıflarında güçlü performans elde edilmiştir.

3.4.2. Hiperparametre Optimizasyonu

GridSearchCV yöntemi ile $C=[0.01, 0.1, 1, 10]$ ve $\text{penalty}=['l2']$ değerleri denenmiştir. Optimizasyon sonucunda en iyi parametreler $C=1$ ve $\text{penalty}=l2$ olarak belirlenmiştir; varsayılan değerlerin veri seti için zaten uygun olduğu doğrulanmıştır.

Tablo 10

Gridsearchcv Sonrası Optimize Lojistik Regresyon Modeli ($C=1, L2$) Performans Sonuçları.

Sınıf	Precision	Recall	F1-Score	Support
High	0.61	0.68	0.64	57
Low	0.48	0.52	0.50	46
Moderate	0.99	0.95	0.97	154
Severe	0.86	0.74	0.80	43
Accuracy			%80.7	300
Ortalama	0.74	0.73	0.73	300

Optimize model %80.7 doğruluk ile başlangıç modeliyle aynı performansı sürdürmüştür. Bu tutarlılık modelin kararlı ve stabil bir yapıya sahip olduğunu kanıtlamaktadır.

3.4.3. Genel Değerlendirme

Lojistik Regresyon, başlangıç aşamasında en yüksek doğruluğu sağlamıştır. Yorumlanabilir katsayı yapısı ve hesaplama verimliliği ile pratik uygulamalar için güçlü bir seçenek sunmaktadır.

3.5. Model Performans Karşılaştırması

Üç algoritmanın başlangıç ve optimize sonuçları Tablo 11'de karşılaştırmalı olarak sunulmuştur.

Tablo 11

Tüm Modellerin Karşılaştırmalı Performans Sonuçları

Model	Accuracy	Precision	Recall	F1-Score
KNN (baseline, k=5)	%70.7	0.61	0.60	0.60
KNN (optimize, k=3)	%71.7	0.62	0.60	0.61
RF (baseline)	%80.3	0.74	0.73	0.73
RF (optimize, n=100)	%79.3	0.72	0.70	0.71
Lojistik Reg. (baseline)	%80.7	0.74	0.73	0.73
Lojistik Reg. (opt.) *	%80.7	0.74	0.73	0.73

Tablo 11 incelendiğinde Lojistik Regresyon'un başlangıç aşamasında en yüksek doğruluğa (%80.7) ulaştığı görülmektedir. Random Forest tekrarlı öğrenme ortalamasında (%81.4) öne çıkmıştır. KNN ise her iki aşamada da (~%71) diğer modellerin belirgin şekilde gerisinde kalmıştır.


3.6. Tekrarlı Öğrenme ile Model Kararlılığı

Model performansının tek bir veri bölünmesine bağlı kalmaması amacıyla seed=1'den seed=30'a kadar 30 farklı random seed değeriyle tekrarlı öğrenme gerçekleştirilmiştir. Her iterasyonda veri seti yeniden bölünmüş, SMOTE uygulanmış ve modeller yeniden eğitilmiştir.


Tablo 12

30 Farklı Random Seed İle Tekrarlı Değerlendirme Özeti.

Model	Ort. Doğruluk	Kazanma (30 denemede)
KNN	%73.7	0 / 30
Random Forest	%81.4	20 / 30
Lojistik Regresyon	%80.5	12 / 30



Şekil 12. 30 tekrar ortalama doğruluk bar chart.



Şekil 13. 30 seed doğruluk dağılımı boxplot.

Tablo 12, Şekil 12 ve Şekil 13 birlikte değerlendirildiğinde Random Forest'in 30 denemeden 20'sinde birinci olduğu ve en yüksek ortalama doğruluğa (%81.4) ulaştığı görülmektedir. Lojistik Regresyon (%80.5) yakın performans sergilemiştir. KNN ise 30 denemede hiçbir kez birinci olamamıştır.

3.7. İstatistiksel Karşılaştırma

Algoritmaların performans farklarının istatistiksel açıdan anlamlı olup olmadığını belirlemek amacıyla McNemar testi ve Wilcoxon işaretli-sıralama testi uygulanmıştır.

McNemar testi, aynı test kümesi üzerinde iki sınıflandırıcının tahmin hatalarını karşılaştıran bağımlı örneklem testidir. Modeller aynı veri seti üzerinde değerlendirildiğinden bağımsız gruplar için tasarlanmış ki-kare yerine McNemar testi tercih edilmiştir.

Wilcoxon işaretli-sıralama testi ise 30 farklı seed ile elde edilen doğruluk dizilerini karşılaştırmaktadır. Normal dağılım varsayımı gerektirmeyen bu parametrik olmayan test bağımlı örneklem için uygundur ve McNemar testini tamamlayıcı nitelikte ek istatistiksel güç katmaktadır.

Her iki testte de H_0 : İki model arasında istatistiksel olarak anlamlı fark yoktur ($\alpha=0.05$).

Tablo 13


McNemar Ve Wilcoxon Testi Karşılaştırma Sonuçları.

Karşılaştırma	McNemar p	Wilcoxon p	Sonuç
RF vs Lojistik Reg.	0.618	0.057	H_0 reddedilemez
KNN vs Lojistik Reg.	0.001	0.000002	H_0 reddedildi
KNN vs Random Forest	0.003	0.000002	H_0 reddedildi

Tablo 13 incelendiğinde RF ile Lojistik Regresyon arasında her iki testte de istatistiksel olarak anlamlı fark bulunmamıştır (McNemar $p=0.618$, Wilcoxon $p=0.057$; her ikisi de $p>0.05$); H_0 reddedilememiş, iki model istatistiksel açıdan eşdeğer kabul edilmiştir. KNN ile diğer modeller arasında ise güçlü biçimde anlamlı farklar saptanmıştır ($p<0.01$ ve $p=0.000002$); H_0 reddedilmiştir.

3.8. Final Modelin Seçimi ve Değerlendirilmesi

İstatistiksel testler RF ile Lojistik Regresyon'un istatistiksel açıdan eşdeğer performans sergilediğini ortaya koymuştur (McNemar $p=0.618$, Wilcoxon $p=0.057$). Her iki model de KNN'den anlamlı ölçüde üstündür ($p<0.01$). Final model olarak yorumlanabilirlik avantajı ve düşük hesaplama maliyeti nedeniyle Lojistik Regresyon seçilmiştir. Final model 700 gözlemlik eğitim seti üzerinde yeniden eğitilmiştir.



Şekil 14

Final Model (Lojistik Regresyon) Karışıklık Matrisi — Test Seti

Tablo 14*Final Model Eğitim Ve Test Başarı Ölçütleri*

Sınıf	Precision	Recall	F1-Score	Support
High	0.61	0.68	0.64	57
Low	0.48	0.52	0.50	46
Moderate	0.99	0.95	0.97	154
Severe	0.86	0.74	0.80	43
Eğitim Acc.			%82.2	700
Accuracy			%80.7	300
Ortalama	0.74	0.73	0.73	300

Tablo 14 ve Şekil 14 birlikte incelendiğinde eğitim (%82.2) ve test (%80.7) doğruluklarının birbirine yakın olduğu görülmektedir; bu durum modelin aşırı öğrenme yapmadığını ve güçlü genelleme kapasitesi geliştirdiğini doğrulamaktadır. Moderate sınıfı en yüksek ($F1=0.97$), Low sınıfı ise en düşük ($F1=0.50$) performansı sergilemiştir.

3.8.1. Genel Değerlendirme

Bu çalışmada Random Forest (%81.4 ortalama) en yüksek tekrarlı öğrenme başarısını elde etmiş; Lojistik Regresyon (%80.5) istatistiksel olarak eşdeğer performans sergilemiştir. Yorumlanabilirlik ve verimlilik açısından Lojistik Regresyon final model olarak seçilmiştir. KNN ise her iki değerlendirme türünde de istatistiksel olarak anlamlı biçimde geride kalmıştır.

4. Tartışma

Bu çalışmada elde edilen bulgular, dijital oyun kullanım alışkanlıklarının bireylerin psikolojik ve davranışsal özellikleri ile istatistiksel olarak anlamlı ilişkiler içerdiğini göstermektedir. Özellikle uyku süresi, sosyal izolasyon düzeyi ve ruh hâli gibi değişkenlerin oyun bağımlılığı riski ile ilişkili olduğu hem keşifsel veri analizi hem de model sonuçları ile desteklenmiştir. Bu ilişkilerin istatistiksel olarak anlamlı olması, elde edilen bulguların güvenilirliğini artırmaktadır. Literatürde yer alan çalışmalar da benzer şekilde oyun bağımlılığı ile psikolojik faktörler arasında güçlü ilişkiler bulunduğunu ortaya koymaktadır [5,6].

Makine öğrenmesi modelleri karşılaştırıldığında, KNN algoritmasının diğer modellere kıyasla daha düşük performans sergilediği görülmüştür. Yapılan istatistiksel testler sonucunda bu farkın anlamlı olduğu belirlenmiştir ($p < 0.01$). Bu durum, KNN algoritmasının mesafe temelli yapısı nedeniyle sınıf dengesizliği ve veri dağılımına duyarlı olmasından kaynaklanmaktadır. Buna karşılık Random Forest ve Lojistik Regresyon modelleri daha yüksek ve dengeli performans göstermiştir. Random Forest modeli topluluk öğrenme yapısı sayesinde daha güçlü genelleme başarısı sergilerken, Lojistik Regresyon modeli benzer performansı daha kararlı ve yorumlanabilir bir yapı ile sağlamıştır.

Bu çalışma kapsamında elde edilen model performanslarının karşılaştırması Tablo 15'te sunulmuştur.

Tablo 15

Modellerin Karşılaştırmalı Performans Sonuçları

Model	Accuracy	Precision	Recall	F1-Score
KNN	%71.7	0.62	0.60	0.61
Random Forest	%81.4 (ortalama)	0.72	0.70	0.71
Lojistik Regresyon	%80.7	0.74	0.73	0.73

Tablo 15 incelendiğinde Random Forest ve Lojistik Regresyon modellerinin KNN'e göre daha yüksek performans sergilediği açıkça görülmektedir. Yapılan McNemar ve Wilcoxon testleri sonucunda Random Forest ile Lojistik Regresyon arasında istatistiksel olarak anlamlı bir fark bulunmadığı belirlenmiştir ($p > 0.05$). Buna karşın KNN ile diğer modeller arasındaki farkların istatistiksel olarak anlamlı olduğu tespit edilmiştir ($p < 0.01$). Bu sonuçlar, Random Forest ve Lojistik Regresyon modellerinin istatistiksel olarak benzer düzeyde güçlü performans sergilediğini, KNN modelinin ise veri yapısına daha az uygun olduğunu göstermektedir.

Elde edilen bulgular literatür ile karşılaştırıldığında, oyun bağımlılığı riskinin yalnızca oyun süresi ile açıklanamayacağı, psikolojik ve sosyal faktörlerin birlikte değerlendirilmesi gerektiği sonucu desteklenmektedir. Özellikle sosyal izolasyon ve olumsuz ruh hâli ile bağımlılık riski arasındaki ilişki, önceki çalışmalarla istatistiksel olarak uyumlu sonuçlar ortaya koymaktadır.

Genel olarak değerlendirildiğinde, makine öğrenmesi yöntemlerinin oyun bağımlılığı riskinin tahmin edilmesinde etkili ve güvenilir sonuçlar ürettiği görülmektedir. Bu çalışma, hem literatürdeki bulguları doğrulamakta hem de bu ilişkilerin veri temelli ve istatistiksel olarak modellenebileceğini göstermektedir.

5. Sonuç ve Öneriler

5.1. Sonuçlar

Bu çalışmada dijital oyun kullanımına ilişkin psikolojik ve davranışsal veriler kullanılarak oyun bağımlılığı riski makine öğrenmesi algoritmaları ile başarılı biçimde sınıflandırılmıştır. Elde edilen sonuçlara göre Random Forest ve Lojistik Regresyon modelleri en yüksek performansı göstermiştir. Yapılan istatistiksel analizler, bu iki model arasında anlamlı bir fark bulunmadığını ortaya koymuştur ($p > 0.05$).

Buna karşın KNN modelinin diğer modellere göre istatistiksel olarak anlamlı düzeyde daha düşük performans sergilediği belirlenmiştir ($p < 0.01$). Bu durum, veri yapısına uygun model seçiminin önemini ortaya koymaktadır.

Çalışmanın en önemli bulgularından biri, oyun bağımlılığı riskinin yalnızca oyun süresi ile açıklanamayacağıdır. Psikolojik durum, sosyal izolasyon ve davranışsal faktörlerin birlikte değerlendirilmesi, bağımlılık riskinin daha doğru tahmin edilmesini sağlamaktadır.

Modelin eğitim ve test performanslarının birbirine yakın olması, aşırı öğrenme (overfitting) probleminin oluşmadığını ve modelin güçlü bir genelleme yeteneğine sahip olduğunu göstermektedir. Bu durum, geliştirilen modelin gerçek dünya uygulamalarında kullanılabilir olduğunu ortaya koymaktadır.

5.2. Öneriler

Daha büyük ve farklı popülasyonları içeren veri setleri ile modelin genellenebilirliği artırılabilir.

XGBoost, SVM ve Gradient Boosting gibi ileri algoritmalar ile karşılaştırmalar yapılabilir.

Psikolojik değişkenlerin daha detaylı ölçüldüğü veri setleri kullanılarak model performansı geliştirilebilir.

Gerçek zamanlı veri toplama sistemleri ile model dinamik hale getirilebilir.

Geliştirilen model, erken uyarı sistemi olarak kullanılarak bireylerin bağımlılık riski önceden tespit edilebilir.

6. REFERANSLAR

- [1] F. Koral, K. Alptekin, Dijital oyun bağımlılığı: Bir derleme çalışması, Karatay Sosyal Araştırmalar Dergisi. 11 (2023), 283–308.
- [2] V. D. Çakır, Lise öğrencilerinin dijital oyun bağımlılığının yalnızlık ve internet aile stilleri arasındaki ilişkisi ve dijital oyun bağımlılığının çeşitli demografik değişkenler açısından incelenmesi, Yüksek Lisans Tezi, Bahçeşehir Üniversitesi Lisansüstü Eğitim Enstitüsü, Eğitim Teknolojileri Anabilim Dalı, İstanbul, 2021.
- [3] R. Bozkurt, Spor Bilimleri Fakültesi öğrencilerinin dijital oyun bağımlılığı ve dijital oyun bağımlılığına yönelik farkındalık düzeylerinin incelenmesi, Yüksek Lisans Tezi, Selçuk Üniversitesi Sağlık Bilimleri Enstitüsü, Spor Yöneticiliği Anabilim Dalı, Konya, 2023.
- [4] I. Granic, A. Lobel, R. Engels, The benefits of playing video games, American Psychologist. 69 (2014), 66–78.
- [5] D. Kuss, M. Griffiths, Internet gaming addiction: A systematic review, International Journal of Mental Health and Addiction. 10 (2012), 278–296.
- [6] T. Ribeiro, Digital Games and Mental Health Dataset, Harvard Dataverse, <https://dataverse.harvard.edu/dataset.xhtml?persistentId=doi:10.7910/DVN/YIGTVD>
- [7] L. Breiman, Random forests, Machine Learning, 45 (2001), 5–32.
- [8] World Health Organization, International Classification of Diseases 11th Revision (ICD-11), WHO, Geneva, 2018.
- [9] American Psychiatric Association, Diagnostic and Statistical Manual of Mental Disorders (DSM-5-TR), APA Publishing, Washington DC, 2022.